



Fundusze
Europejskie
Wiedza Edukacja Rozwój



Rzeczpospolita
Polska

Politechnika
Warszawska

Unia Europejska
Europejski Fundusz Społeczny



WSTĘP DO MATEMATYKI FINANSOWEJ

BARTOSZ KOŁODZIEJEK

WYDZIAŁ MATEMATYKI I NAUK INFORMACYJNYCH

Laboratoria 7

Projekt „NERW 2 PW. Nauka - Edukacja - Rozwój - Współpraca” współfinansowany ze środków Unii Europejskiej w ramach Europejskiego Funduszu Społecznego.

Zadanie 10 pn. „Modyfikacja programów studiów na kierunkach prowadzonych przez Wydział Matematyki i Nauk Informacyjnych”, realizowane w ramach projektu „NERW 2 PW. Nauka - Edukacja - Rozwój - Współpraca”, współfinansowanego jest ze środków Unii Europejskiej w ramach Europejskiego Funduszu Społecznego.

6 czerwca 2023

0.1. **L7 - Metody MCMC.** Ćwiczmy metody MCMC (Markov Chain Monte Carlo). Będziemy całkowali metodami Monte Carlo z wykorzystaniem łańcuchów Markowa. Metody te opierają się o twierdzenia ergodyczne, a nie o prawa wielkich liczb jak tradycyjne metody Monte Carlo.

(1) Przypomnienie o Łańcuchach Markowa (ŁM):

Niech \mathcal{S} będzie przeliczalnym zbiorem - będziemy go nazywali przestrzenią stanów.

- Ciąg zmiennych losowych $(X_n)_{n=0}^{\infty}$ o wartościach w \mathcal{S} nazywamy łańcuchem Markowa, jeśli dla każdego $n \in \mathbb{N}$ i każdego ciągu $s_0, s_1, \dots, s_n \in \mathcal{S}$ zachodzi

$$\mathbb{P}(X_n = s_n | X_{n-1} = s_{n-1}, \dots, X_1 = s_1, X_0 = s_0) = \mathbb{P}(X_n = s_n | X_{n-1} = s_{n-1})$$

o ile powyższe prawdopodobieństwa mają sens (czyli zdarzenia w warunkowaniach mają dodatnie prawdopodobieństwa).

- Łańcuch Markowa nazywamy jednorodnym (JŁM), gdy

$$\mathbb{P}(X_n = s_n | X_{n-1} = s_{n-1}) = \mathbb{P}(X_1 = s_n | X_0 = s_{n-1}) \quad \text{dla każdego } n.$$

Dalej będziemy rozważali tylko jednorodne ŁM.

- Oznaczmy $p_{ij} = \mathbb{P}(X_1 = s_j | X_0 = s_i)$. Będziemy utożsamiali stan s_i z jego indeksem i . Wtedy, macierz $P = (p_{ij})_{i,j \in \mathcal{S}}$ nazywamy macierzą przejścia (w jednym kroku).

Macierz P jest macierzą stochastyczną, tzn. jej wyrazy są nieujemne, a jej wiersze sumują się do 1.

Rozkład JŁM $(X_n)_{n=0}^{\infty}$ jest jednoznacznie określony przez macierz P oraz rozkład początkowy (rozkład X_0).

- Definiujemy również macierz przejścia w n krokach poprzez

$$P(n) = (p_{ij}(n))_{i,j \in \mathcal{S}} := P^n.$$

- Mówimy, że
 - stan s_k jest osiągalny ze stanu s_j (ozn.: $s_j \rightarrow s_k$), jeśli $p_{jk}(n) > 0$ dla pewnego n ,
 - stany s_k i s_j komunikują się ($s_k \leftrightarrow s_j$), jeśli $s_j \rightarrow s_k$ oraz $s_k \rightarrow s_j$.
- JŁM nazywamy nieprzywiedlnym, jeśli wszystkie jego stany wzajemnie się komunikują.
- Stan s_j nazywamy stanem powracającym, jeśli JŁM startujący ze stanu s_j ($X_0 = s_j$), powróci do niego z prawdopodobieństwem 1 w skończonym (aczkolwiek dowolnie długim) czasie:

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} \{X_n = s_j\} | X_0 = s_j\right) = 1.$$

W przeciwnym przypadku (gdy powyżej jest < 1), stan taki nazywamy stanem chwilowym.

▲ Twierdzenie Lévy'ego: Błądzenie losowe w \mathbb{Z}^d jest powracające wtedy i tylko wtedy, gdy $d \in \{1, 2\}$.

- Okresem stanu j nazywamy liczbę $o(j) = \text{NWD}\{n: p_{jj}(n) > 0\}$.
- **TW.** W nieprzywiedlnym JŁM wszystkie stany są tego samego typu: jeżeli jeden jest powracający (odp. chwilowy, okresowy o okresie d), to wszystkie jego stany są powracające (chwilowe, okresowe o okresie d).
- 👁 Z uwagi na powyższy wynik, dla nieprzywiedlnych JŁM, jest sens mówić o łańcuchach powracających, chwilowych i okresowych. Mówimy, że JŁM jest okresowy jeśli wszystkie jego stany są okresowe o okresie $d > 1$ (w przeciwnym przypadku, JŁM nazwiemy nieokresowym).
- Mówimy, że rozkład prawdopodobieństwa $\pi = (\pi_j)_{j \in \mathcal{S}}$ jest rozkładem stacjonarnym dla JŁM o macierzy przejścia P , jeśli (wektor π tutaj jest poziomy!)

$$\pi = \pi \cdot P,$$

czyli $\sum_{j \in \mathcal{S}} \pi_j = 1$, $\pi_j \geq 0$ oraz $\pi_j = \sum_{i \in \mathcal{S}} \pi_i p_{ij}$.

▲ Jeśli X_0 ma rozkład stacjonarny π , to dla każdego n

$$X_n \stackrel{d}{=} X_0 \sim \pi.$$

- **TW.** (Twierdzenie ergodyczne). Niech $(X_n)_{n \geq 0}$ będzie nieprzywiedlnym i nieokresowym łańcuchem Markowa na skończonej przestrzeni stanów \mathcal{S} z macierzą przejścia P . Wtedy:
 - istnieje dokładnie jeden rozkład stacjonarny π dla macierzy P ,
 - $\pi_i > 0$ dla $i \in \mathcal{S}$,

(c) dla każdego $i \in \mathcal{S}$,

$$p_{ij}(n) \xrightarrow{n \rightarrow \infty} \pi_j, \quad j \in \mathcal{S}$$

oraz dla dowolnego rozkładu X_0 zachodzi

$$\mathbb{P}(X_n = j) \xrightarrow{n \rightarrow \infty} \pi_j, \quad j \in \mathcal{S}$$

(d) dla dowolnego X_0 zachodzi

$$\boxed{\frac{1}{n} \sum_{k=1}^n \mathbb{1}_{\{X_k=j\}} \xrightarrow{1} \pi_j, \quad j \in \mathcal{S}.}$$

▲ Zauważmy, że warunek (d) implikuje dla dowolnej funkcji f na \mathcal{S} ,

$$\frac{1}{n} \sum_{k=1}^n f(X_k) = \frac{1}{n} \sum_{k=1}^n f(X_k) \sum_{i \in \mathcal{S}} \mathbb{1}_{\{X_k=i\}} = \sum_{i \in \mathcal{S}} f(i) \frac{1}{n} \sum_{k=1}^n \mathbb{1}_{\{X_k=i\}} \xrightarrow{1} \sum_{i \in \mathcal{S}} f(i) \pi_i = \mathbb{E}_\pi[f(X)].$$


▲ Warunek (d) przypomina Mocne Prawo Wielkich Liczb, ale faktycznie jest to niezależne twierdzenie. Zmienne $(X_n)_n$ są bardzo zależne!

- Szybkość zbieżności możemy próbować oceniać za pomocą CTG w wersji dla łańcuchów Markowa (pamiętajmy jednak, że w zastosowaniach rzadko X_0 ma rozkład stacjonarny, a jedynie wiemy, że rozkład X_n dąży do stacjonarnego - bywa że bardzo szybko).

TW. (CTG dla ŁM) Jeśli rozkład X_0 jest stacjonarny, to

$$\frac{1}{\sqrt{n}} \left(\sum_{k=1}^n (f(X_k) - \mathbb{E}_\pi[f(X)]) \right) \xrightarrow{d} Z \sim N(0, \sigma_f^2),$$

gdzie $\sigma_f^2 = \text{Var}[f(X_0)] + 2 \sum_{k=1}^{\infty} \text{Cov}[f(X_0), f(X_k)]$.

-  JŁM nazywamy odwracalnym (*reversible*), jeśli istnieje taki rozkład prawdopodobieństwa π na \mathcal{S} , że zachodzi

$$\pi_i p_{ij} = \pi_j p_{ji}, \quad \forall i, j \in \mathcal{S}.$$

▲ Jeśli JŁM jest odwracalny, to π z powyższego warunku jest jego rozkładem stacjonarnym:

$$\pi_j = \pi_j \cdot 1 = \pi_j \cdot \sum_{i \in \mathcal{S}} p_{ji} = \sum_{i \in \mathcal{S}} \pi_i p_{ij}.$$

▲ Odwracalne ŁM to szczególnie ładne ŁM, ponieważ łatwo dla nich stwierdzić, że coś jest rozkładem stacjonarnym.

- ▲ Powyżej rozważaliśmy ŁM o dyskretnym przestrzeni stanów, ale wszystko można przenieść na ogólniejsze przestrzenie \mathcal{S} (w szczególności, gdy \mathcal{S} jest zbiorem nieprzeliczalnym). Wtedy wiele obiektów trzeba przeddefiniować, poniżej rozważymy (tylko) miary absolutnie ciągle względem miary Lebesgue'a oraz $\mathcal{S} = \mathbb{R}^d$.

Po pierwsze, ŁM nazywamy procesem stochastycznym, którego gęstości warunkowe spełniają warunek

$$f_{X_n|X_{n-1}=s_{n-1}, \dots, X_1=s_1, X_0=s_0}(s_n) = f_{X_n|X_{n-1}=s_{n-1}}(s_n), \quad s_i \in \mathcal{S}, i = 0, \dots, n.$$

Taki proces nazywamy jednorodnym, jeśli

$$f_{X_n|X_{n-1}=s_{n-1}}(s_n) = f_{X_1|X_0=s_{n-1}}(s_n) \quad \text{dla każdego } n.$$

Nie istnieje coś takiego jak macierz przejścia $(p_{ij})_{ij}$ w jednym kroku, ponieważ stany są "ciągłe". Zamiast tego definiuje się gęstość prawdopodobieństwa przejścia w jednym kroku, czyli gęstość warunkową X_1 pod warunkiem X_0 ,

$$p(y | x) := f_{X_1|X_0=x}(y).$$

Zatem $y \mapsto p(y | x)$ jest gęstością dla każdego $x \in \mathcal{S}$. Wtedy rozkładem stacjonarnym π (a właściwie gęstością tego rozkładu) ŁM o prawdopodobieństwie przejścia zadany jak powyżej to funkcja spełniająca dla $y \in \mathcal{S}$

$$\pi(y) = \int_{\mathcal{S}} p(y | x) \pi(x) dx.$$

Jeśli ŁM jest odwracalny, tzn. dla pewnej gęstości π zachodzi

$$\pi(x) p(y | x) = \pi(y) p(x | y), \quad \forall x, y \in \mathcal{S},$$

to π z warunku powyżej jest gęstością rozkładu stacjonarnego.

Istnieje wersja Twierdzenia ergodycznego dla takich ŁM. Warunek (d) z powyższego twierdzenia jest zastępowany przez

$$\frac{1}{n} \sum_{k=1}^n f(X_k) \xrightarrow{1} \int_{\mathcal{S}} f(x) \pi(x) dx = \mathbb{E}_{\pi}[f(X)]$$

dla “ładnych” funkcji f (np. ciągłych i ograniczonych, ale wystarczy po prostu całkowalnych względem π).

- (2) Problem: założmy, że π jest pewnym rozkładem prawdopodobieństwa na \mathcal{S} . Celem jest estymacja wartości oczekiwanej z pewnej funkcji $h: \mathcal{S} \rightarrow \mathbb{R}$, czyli

$$\mathbb{E}_{\pi}[h(X)] = \sum_{s \in \mathcal{S}} h(s) \pi_s \quad \left(\mathbb{E}_{\pi}[h(X)] = \int_{\mathcal{S}} h(s) \pi(s) ds \right).$$

Jeśli mamy doczynienia z sytuacją, gdy łatwo jest generować z rozkładu π , to możemy korzystać ze zwykłej metody Monte Carlo.

Metody MCMC pomagają w sytuacji, gdy

- rozkład π jest znany tylko z dokładnością do stałej normującej, tzn. znamy funkcję $f: \mathcal{S} \rightarrow \mathbb{R}_+$ taką, że

$$\pi_i = c f(i) \quad (\pi(x) = c f(x)),$$

ale stała c nie jest znana.

Oczywiście, $c = 1/(\sum_{i \in \mathcal{S}} f(i))$ ($c = 1/\int_{\mathcal{S}} f(x) dx$), ale w zastosowaniach zbiór \mathcal{S} bywa tak duży (przy dużej kosztowności obliczania f), że znalezienie tej sumy może nie być możliwe w interesującym nas horyzoncie czasowym.

- (3) Niech $f: \mathcal{S} \rightarrow \mathbb{R}_+$ będzie funkcją jak powyżej. Żeby zrealizować nasz cel, czyli estymować $\mathbb{E}_{\pi}[h(X)]$, gdzie

$$\pi := (c f(i): i \in \mathcal{S}),$$

skonstruujemy JŁM o rozkładzie stacjonarnym danym przez π .

▲ Z konstrukcji tego ŁM będzie wynikało, że wystarczy, nam wiedza o f , a znajomość c oraz π nie jest konieczna. Taki typ problemów spotykany jest bardzo naturalnie podczas uprawiania statystyki Bayesowskiej, o czym później.

Niech $Q = (q_{ij})_{i,j \in \mathcal{S}}$ będzie (na tym etapie dowolną, ale myślny już że nieprzywiedlną) macierzą przejścia na przestrzeni stanów \mathcal{S} . Za pomocą macierzy Q skonstruujemy macierz P dla której π będzie rozkładem stacjonarnym.

👁 Uwaga: w literaturze zamiast q_{ij} można spotkać oznaczenie $q(j|i)$.

Zdefiniujmy

$$\rho_{ij} = \frac{\pi_j q_{ji}}{\pi_i q_{ij}} = \frac{f(j) q_{ji}}{f(i) q_{ij}} \quad \text{oraz} \quad \alpha_{ij} = \min\{\rho_{ij}, 1\}$$

oraz rozważmy macierz $P = (p_{ij})_{i,j \in \mathcal{S}}$ zadaną przez

$$p_{ij} = \begin{cases} q_{ij} \alpha_{ij}, & \text{jeśli } i \neq j, \\ 1 - \sum_{j \neq i} q_{ij} \alpha_{ij}, & \text{jeśli } i = j. \end{cases}$$

Macierz P jest oczywiście macierzą stochastyczną. Ponadto mamy dla $i \neq j$,

$$\pi_i p_{ij} = \begin{cases} \pi_j q_{ji}, & \rho_{ij} < 1, \\ \pi_i q_{ij}, & \rho_{ij} \geq 1. \end{cases}$$

oraz

$$\pi_j p_{ji} = \begin{cases} \pi_i q_{ij}, & \rho_{ji} < 1, \\ \pi_j q_{ji}, & \rho_{ji} \geq 1. \end{cases}$$

Żeby pokazać odwracalność ŁM o macierzy przejścia P (czyli $\pi_i p_{ij} = \pi_j p_{ji}$) wystarczy zauważyć, że $\rho_{ij} = 1/\rho_{ji}$. To oznacza z kolei, że π jest rozkładem stacjonarnym.

Powstaje ważne pytanie, w jaki sposób generować ŁM o macierzy przejścia P ? Okazuje się to być bardzo łatwe, ale o tym następnym razem.

0.2. L7 - Metody MCMC - ciąg dalszy.

- (1) Przypomnijmy, że celem jest estymacja wielkości

$$\mathbb{E}_\pi[h(X)] = \begin{cases} \sum_{s \in \mathcal{S}} h(s) \pi_s, \\ \int_{\mathcal{S}} h(x) \pi(s) ds, \end{cases}$$

gdzie π jest pewnym rozkładem prawdopodobieństwa.

- (2) Pomysł: skonstruujemy JŁM
- $(X_n)_n$
- o rozkładzie stacjonarnym
- π
- i skorzystamy z twierdzenia ergodycznego:

$$\frac{1}{n} \sum_{k=1}^n h(X_k) \xrightarrow{1} \mathbb{E}_\pi[h(X)].$$

- (3) Z konstrukcji tego JŁM wynika, że wystarczy nam znajomość
- π
- z dokładnością do stałej, czyli znamy funkcję
- f
- , taką że
- $\pi = c \cdot f$
- , ale nie znamy stałej
- c
- . Tym samym, dla zadanej funkcji
- f
- (całkowalnej, nieujemnej) będziemy estymować

$$\mathbb{E}_\pi[h(X)] = \begin{cases} \frac{\sum_{s \in \mathcal{S}} h(s) f(s)}{\sum_{s \in \mathcal{S}} f(s)}, \\ \frac{\int_{\mathcal{S}} h(x) f(s) ds}{\int_{\mathcal{S}} f(s) ds}. \end{cases}$$

- (4) Rozważmy najpierw przypadek dyskretny. Niech
- $Q = (q_{ij})_{i,j \in \mathcal{S}}$
- będzie nieprzywiedlną macierzą przejścia na przestrzeni stanów
- \mathcal{S}
- . Pokazaliśmy już wcześniej, że macierz
- $P = (p_{ij})_{i,j \in \mathcal{S}}$
- zdefiniowana poniżej jest

- macierzą stochastyczną,
- JŁM o tej macierzy jest odwracalny, tzn. $\pi_i p_{ij} = \pi_j p_{ji}$,
- rozkładem stacjonarnym tego łańcucha jest π .

☞ Niech

$$\rho_{ij} = \frac{\pi_j q_{ji}}{\pi_i q_{ij}} = \frac{f(j) q_{ji}}{f(i) q_{ij}} \quad \text{oraz} \quad \alpha_{ij} = \min\{\rho_{ij}, 1\}$$

oraz $P = (p_{ij})_{i,j \in \mathcal{S}}$, gdzie

$$p_{ij} = \begin{cases} q_{ij} \alpha_{ij}, & \text{jeśli } i \neq j, \\ 1 - \sum_{j \neq i} q_{ij} \alpha_{ij}, & \text{jeśli } i = j. \end{cases}$$

- (5) Powstaje ważne pytanie, w jaki sposób generować ŁM o macierzy przejścia
- P
- ? Okazuje się to być bardzo łatwe: odpowiednio modyfikujemy JŁM o macierzy
- Q
- . Poniższy algorytm nazywa się
- algorytmem Metropolisa-Hastingsa*
- :

Algorytm 0.1 (Algorytm Metropolisa-Hastingsa)

Zainicjalizuj $X_0 \in \mathcal{S}$. [Dowolnie jak, byleby przyszłość była niezależna od tego wyboru.]

Dla chwil $t = 1, 2, \dots$ wykonuj następujące kroki:

- w chwili t wygeneruj stan Y zgodnie z rozkładem $(q_{X_{t-1},k} : k \in \mathcal{S})$, [Innymi słowy, będąc w stanie X_{t-1} , zrób krok ŁM o macierzy przejścia Q , nowy stan nazwij Y],
- Zaakceptuj stan Y z prawdopodobieństwem $\alpha_{X_{t-1},Y}$ i wtedy połącz $X_t = Y$. W przypadku braku akceptacji nie zmieniaj stanu, tzn. połącz $X_t = X_{t-1}$. Innymi słowy,

$$X_t = \begin{cases} Y, & \text{z prawdopodobieństwem } \alpha_{X_{t-1},Y}, \\ X_{t-1}, & \text{w p.p.} \end{cases}$$

▲ O ile dla tak skonstruowanego ŁM $(X_n)_n$ zachodzi Twierdzenie ergodyczne, to wiemy, że dla dowolnej funkcji h na \mathcal{S} mamy

$$\frac{1}{n} \sum_{k=1}^n h(X_k) \xrightarrow{1} \sum_{i \in \mathcal{S}} h(i) \pi_i.$$

▲ Zauważmy, że jeśli JŁM generowany przez macierz Q był nieprzywiedlny, to skonstruowany ŁM $(X_n)_n$ będzie nieprzywiedlny i nieokresowy.

☞ Macierz przejścia Q (a właściwie jej wiersze) nazywana jest *proposal distribution*.

Komentarze:

- rozważmy symetryczny rozkład proposal distribution, tzn. $q_{ij} = q_{ji}$. Powiedzmy, że nasz ŁM jest w stanie i oraz wylosowaliśmy stan j zgodnie z Q . Stan ten jest akceptowany z prawdopodobieństwem $\alpha_{ij} = \min\{\frac{f(j)}{f(i)}, 1\}$. W szczególności, jeśli $f(j) \geq f(i)$, to stan j zostanie automatycznie akceptowany.

Skonstruowany ŁM chętnie przebywa dłużej w stanach, gdzie funkcja f jest duża. W pewnym sensie, jest tutaj podobieństwo do importance sampling, przy czym tutaj kolejne wyrazy ciągu są zależne.

- Jak dobrać proposal distribution? Mamy tu pewną dowolność.

W idealnym świecie byśmy wybrali $Q_{ij} = \pi_j$, dzięki czemu nowe stany zawsze by były akceptowane ($\alpha_{ij} = 1$), a ciąg $(X_n)_n$ byłby i.i.d. Żeby zobaczyć niezależność rozważmy

$$\mathbb{P}(X_n = j, X_{n-1} = i) = \mathbb{P}(X_n = j | X_{n-1} = i) \mathbb{P}(X_{n-1} = i) = Q_{ij} \mathbb{P}(X_{n-1} = i) = \pi_j \mathbb{P}(X_{n-1} = i).$$

Ponieważ nie znamy π , nie możemy jednak dokonać takiego wyboru.

W doborze Q powinniśmy zwrócić uwagę na to by skonstruowany ŁM “możliwie szybko” (ale nie za szybko) eksplorował przestrzeń stanów oraz żeby “dość często” (ale nie za często) akceptował nowe stany.


- W wersji ciągłej, algorytm M-H wygląda bardzo podobnie jak w wersji dyskretniej. Zamiast macierzy przejścia Q musimy zadać rodzinę gęstości (proposal distribution) $y \mapsto q(y | x)$ dla $x \in \mathcal{S}$.

Algorytm 0.2 (Algorytm Metropolisa-Hastingsa, wersja absolutnie ciągła)

Zainicjalizuj $X_0 \in \mathcal{S}$.

Dla chwil $t = 1, 2, \dots$ wykonuj następujące kroki:

- (i) w chwili t wygeneruj stan Y zgodnie z rozkładem o gęstości $y \mapsto q(y | X_{t-1})$,
- (ii) Zaakceptuj stan Y z prawdopodobieństwem $\min\{\frac{f(Y)q(X_{t-1}|Y)}{f(X_{t-1})q(Y|X_{t-1})}, 1\}$ i wtedy połącz $X_t = Y$. W przypadku braku akceptacji połącz $X_t = X_{t-1}$.

- (6)  Bardzo prosty ciągły przykład. Zastosujemy algorytm M-H do generowania zmiennych z rozkładu $N(0, 1)$. Mamy $\mathcal{S} = \mathbb{R}$, a jako proposal distribution wybierzmy (symetryczny) rozkład

$$q(y | x) = q(y - x),$$

gdzie $q(x) = \frac{1}{2\delta} \mathbb{1}_{[-\delta, \delta]}(x)$ dla pewnej $\delta > 0$. Ponieważ mamy $q(x | y) = q(y | x)$, to $\alpha(x, y) = \min\{\frac{e^{-y^2/2}}{e^{-x^2/2}}, 1\}$ (nie musimy znać stałej normującej gęstość $N(0, 1)$).

Algorytm M-H przysposobiony do tego przykładu wygląda następująco:

Zainicjalizuj $X_0 = 0$ (na przykład).

Dla chwil $t = 1, 2, \dots$ wykonuj następujące kroki:

- (i) w chwili t wygeneruj stan Y zgodnie z rozkładem o gęstości

$$y \mapsto q(y | X_{t-1}) = q(y - X_{t-1}) = \frac{1}{2\delta} \mathbb{1}_{[-\delta, \delta]}(y - X_{t-1}) = \frac{1}{2\delta} \mathbb{1}_{[X_{t-1}-\delta, X_{t-1}+\delta]}(y).$$

Innymi słowy, $Y = X_{t-1} + U$, gdzie $U \sim U([-\delta, \delta])$ jest niezależne od X_{t-1} .

- (ii) Wylosuj liczbę $V \sim U([0, 1])$ oraz oblicz

$$X_t = \begin{cases} Y, & \text{jeśli } V \leq \alpha(X_{t-1}, Y), \\ X_{t-1}, & \text{w p.p.} \end{cases}$$

Co wiemy o tak skonstruowanym ciągu $(X_n)_{n \geq 0}$?

- Twierdzenie mówi, że ma on asymptotycznie rozkład normalny.
- Gdyby $X_0 \sim N(0, 1)$, to wszystkie elementy ciągu miałyby również rozkład $N(0, 1)$.
- Elementy ciągu są bardzo skorelowane, tym bardziej im δ jest mniejsza. Szybkość zbieżności rozkładu empirycznego do rozkładu $N(0, 1)$ zależy od δ .

- (7) Typowym zastosowaniem metod MCMC jest aproksymacja rozkładu a posteriori w statystyce Bayesowskiej. Czym jest statystyka Bayesowska?

- Niech $(f_\theta : \theta)$ będzie rodziną gęstości indeksowanych parametrem θ . (np. $f_\theta(x) = e^{-(x-\theta)^2/2}/\sqrt{2\pi}$).
- Dysponujemy obserwacją X z rozkładu o gęstości f_θ , przy czym nie znamy wartości θ . Na podstawie tej obserwacji chcemy dowiedzieć się czegoś o wykorzystanym θ .

▲ Obserwację X powyżej należy rozumieć ogólnie, może być wielowymiarowa. W szczególności jedna obserwacja z rozkładu wielowymiarowego może być rozumiana jako ciąg obserwacji z rozkładów jednowymiarowych.

- Założmy, że gęstości f_θ są w rzeczywistości gęstościami warunkowymi pod warunkiem pewnej zmiennej losowej Θ , tzn.

$$f_\theta(x) = f_{X|\Theta=\theta}(x).$$

- Założmy, że zmienna losowa Θ ma gęstość f_Θ .

▲ Ten i poprzedni krok są kluczowe w statystyce Bayesowskiej. Opierają się na filozoficznym (nieweryfikowalnym) założeniu, że nieznaną parametr θ jest realizacją pewnej zmiennej losowej. Istnieją dwie

zwalczające się grupy: team częstościowcy (frequentists) oraz team Bayesowscy.

Rozkład zmiennej losowej Θ nazywamy rozkładem a priori; reprezentuje on wiedzę z jaką badacz rozpoczyna badanie. Istnieje wiele kryteriów wyboru rozkładu a priori. Wykorzystuje się np. tzw. rozkłady nieinformacyjne, np. rozkład jednostajny (często dziwny: na $[0, \infty)$ lub \mathbb{R}) lub rozkłady, dla których można podać jawną postać rozkładu a posteriori, o którym poniżej.

- Rozkładem a posteriori nazywamy rozkład o gęstości (gęstość parametru pod warunkiem danych)

$$f_{\Theta|X=x}(\theta) = \frac{f_{(\Theta,X)}(\theta, x)}{f_X(x)} = \frac{f_{X|\Theta=\theta}(x)f_{\Theta}(\theta)}{\int f_{X|\Theta=t}(x)f_{\Theta}(t)dt}.$$

Wersja dyskretna tego powyższego wzoru wygląda następująco

$$\mathbb{P}(\Theta = \theta_k | X = x_i) = \frac{\mathbb{P}(\Theta = \theta_k, X = x_i)}{\mathbb{P}(X = x_i)} = \frac{\mathbb{P}(X = x_i | \Theta = \theta_k)\mathbb{P}(\Theta = \theta_k)}{\sum_j \mathbb{P}(X = x_i | \Theta = \theta_j)\mathbb{P}(\Theta = \theta_j)}.$$

- Standardowym podejściem jest znalezienie parametru θ dla którego gęstość a posteriori jest największa. Gdybyśmy umieli symulować z rozkładu $\Theta | X = x$, to byśmy mogli wyznaczyć ten parametr na podstawie otrzymanego histogramu.
- W konkretnych zastosowaniach obliczenie stałej normującej gęstość rozkładu a posteriori (czyli mianownik) może nie być wykonalne. W takiej sytuacji znamy rozkład a posteriori z dokładnością do stałej normującej, więc zastosowanie metod MCMC jest tutaj bardzo naturalne.